

INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

LICENCIATURA EN CIENCIA DE DATOS



Proyecto Final

PRESENTAN:

Equipo 6

Huerta Rodríguez Sofía

Santiago Trejo Edna Jania

Zhang Tan Rubi

GRUPO:

5AM1

Ciudad de México, a 29 de diciembre del 2025

ÍNDICE

UNIDAD I. INTRODUCCIÓN 1
1.1 RESUMEN 1
1.2 OBJETIVOS 1
1.3 DATOS 1
UNIDAD II. MARCO TEÓRICO 3
2.1. TEMA DE ESTUDIO 3
2.2. MINERÍA DE DATOS 4
2.2.1. AGRUPAMIENTO (CLUSTERING) 4
2.2.2. CLASIFICACIÓN 5
2.2.3. REGLAS DE ASOCIACIÓN 6
2.2.4 METODOLOGÍA DE MINERÍA DE DATOS 7
UNIDAD III. MÉTODO DE DESARROLLO 8
3.1 DESCRIPCIÓN DE DATOS 8
3.2 DESCRIPCIÓN DEL CONJUNTO DE DATOS 17
3.3 TRAMIENTO DE DATOS 25
3.4 TAREA DE MINERÍA A APLICAR 27
3.5 REPRESENTACIÓN DEL MODELO 28
3.5.1 Agrupamiento 28
3.5.2 Clasificación 29
3.5.3 Reglas de Asociación 29
UNIDAD IV. RESULTADOS 30
4.1 AGRUPAMIENTO 30
4.2 CLASIFICACIÓN 31
4.3 REGLAS DE ASOCIACIÓN 33
UNIDAD V. CONCLUSIONES 36
REFERENCIAS 38

ÍNDICE DE TABLAS

Tabla 1. Descripción de las variables 8
Tabla 2. Reglas de Asociación 33

ÍNDICE DE FIGURAS

Figura 1. Porcentaje de nulos por variable 9
Figura 2. Cantidad de reservas por hora 10
Figura 3. Estado final de los viajes 10
Figura 4. Cantidad de viajes por tipo de vehículo 10
Figura 5. Ubicación de origen del viaje 11
Figura 6. Ubicación de destino de viajes 12
Figura 7. Motivo de cancelación de viaje por el cliente 12
Figura 8. Motivo de cancelación de viaje por el conductor 13
Figura 9. Frecuencia de viajes incompletos 13
Figura 10. Frecuencia de razones de viajes incompletos 14
Figura 11. Frecuencia de métodos de pago 14
Figura 12. Tiempo que tarda para que un conductor acepte el viaje 14
Figura 13. Tiempo que tarda el cliente en abordar el vehículo después de su llegada 15
Figura 14. Valor monetario total de los viajes 15
Figura 15. Distancia total recorrida durante los viajes 16
Figura 16. Calificación otorgada al conductor por el cliente 16
Figura 17. Calificación otorgada al cliente por el conductor 16
Figura 18. Resultado consulta 1 17
Figura 19. Resultado consulta 2 18
Figura 20. Resultado consulta 3 19
Figura 21. Continuación resultado consulta 3 20
Figura 22. Resultado consulta 4 20
Figura 23. Resultado consulta 5 21
Figura 24. Resultado consulta 6 21
Figura 25. Resultado consulta 7 22
Figura 26. Resultado consulta 8 23
Figura 27. Resultado consulta 9 23
Figura 28. Resultado consulta 10 24
Figura 29. Modelo de agrupación K-means 28
Figura 30. Modelo de clasificación CART 29
Figura 31. Modelo reglas de asociación 29
Figura 32. Clústeres 30
Figura 33. Resultados modelo de clasificación 31
Figura 34. Resultado de reglas de asociación 33

UNIDAD I. INTRODUCCIÓN

1.1 RESUMEN

Dentro de este proyecto tiene como objetivo aplicar técnicas de minería de datos para el análisis de información relacionada con los viajes realizados dentro de una plataforma de transporte de baja demanda. Nuestro conjunto de datos nombrado como Bookings.csv contine variables de tipo numérico y categórico que describen aspectos económicos, operativos y de calidad del servicio, tales como el valor del viaje, la distancia recorrida, los tiempos de espera y las calificaciones otorgadas por los usuarios y conductores.

Dentro de este proyecto se desarrollaron tres temas importantes dentro de la minería de datos como son agrupamiento, reglas de asociación y clasificación, con el fin de identificar patrones, relaciones y comportamientos relevantes dentro de los datos. Cada uno requirió un proceso especifico de selección y tratamiento de variables, garantizando el correcto funcionamiento de los algoritmos empleados. El proceso metodológico se basó en el enfoque CRISP-DM.

Nuestros resultados lograron identificar distintos perfiles de viajes, relaciones frecuentes entre características del servicio y la predicción del estado de los viajes, y así proporcionaron información útil.

1.2 OBJETIVOS

Objetivo general

Aplicar técnicas de minería de datos para analizar el conjunto de datos Bookigs.csv, con la finalidad de identificar patrones, relaciones y comportamientos relevantes de los viajes realizados dentro de una plataforma de transporte.

Objetivos específicos

- Aplicar tres diversos algoritmos al conjunto de datos (agrupamiento, reglas de asociación y clasificación) para poder realizar relaciones y predicciones al conjunto de datos.
- Evaluar e interpretar los resultados obtenidos de cada modelo aplicado.

1.3 DATOS

El conjunto de datos utilizado en este proyecto fue obtenido de la página web Kaggle del autor Het Mengar, este contiene información sobre reservas del mes de julio del 2024 realizadas en las aplicaciones de transporte bajo demanda como Uber y Ola Cabs. Aunque no se especifica el país o ciudad de donde se recaudaron estos datos, se puede hacer una suposición de que

son de India debido a los registros en las variables que contienen información sobre ubicaciones. Su propósito es ayudar a analistas entender patrones de solicitudes, razones de cancelación y la eficiencia de cada tipo de vehículo. Está compuesto por aproximadamente 103,000 registros, donde cada registro presenta un viaje individual. Asimismo, cuenta con 20 atributos, los cuales incluyen variables numéricas y categóricas, tales como identificadores de viaje.

Fuente: https://www.kaggle.com/datasets/hetmengar/ola-and-uber-ride-booking-and-cancellation-data

UNIDAD II. MARCO TEÓRICO

2.1. TEMA DE ESTUDIO

En la actualidad, el desplazamiento de personas mediante servicios de transporte basados en aplicaciones móviles, conocido también como ride-hailing, ha cambiado por completo la movilidad en las ciudades urbanas. Este servicio brinda una alternativa al transporte público convencional, porque posibilita que los clientes soliciten viajes de un lugar de origen a un destino determinado (Scholl et al., 2021). Las plataformas de ride-hailing han producido un cambio importante en la movilidad urbana a nivel global (Vassallo et al., 2018).

Cada solicitud en sus plataformas genera información sobre cada viaje como la fecha y hora, tiempo de espera, la distancia recorrida en el viaje, entre otros. Una de las empresas más populares internacionalmente es Uber, mientras que en el continente asiático es Ola Cabs (Wang & Yang, 2019).

Es importante mencionar que uno de los principales desafíos asociados con este tipo de servicios es la cancelación de viajes, debido a que afecta tanto al conductor como a la experiencia del usuario y la eficiencia de las plataformas. Cuando el conductor cancela un viaje, los usuarios deben esperar más tiempo y experimentan una mala calidad del servicio, lo que reduce la cantidad de viajes posibles para los demás conductores en el sistema (Uber, 2025).

De acuerdo con Sun et al. (2023), hay elementos que tienen impacto en la probabilidad de que un viaje se complete o sea cancelado, tales como la hora, distancia entre el usuario y el vehículo, tráfico, clima, tiempo de espera y recursos de transporte alternativo disponibles en el momento para el usuario. Las consecuencias de estas cancelaciones afectan a los conductores, debido a que implica tiempo y esfuerzo invertido sin compensación, lo que repercuta en sus ingresos (Uber, 2025).

Las cancelaciones pueden ocurrir desde dos perspectivas, según Wang y Yang (2019):

- Cancelaciones por el cliente: Puede surgir debido a un largo tiempo de espera para que un conductor acepte su solicitud o que el tiempo de recogida sea más largo de lo esperado.
- Cancelaciones por el conductor: Puede surgir por la distancia hasta el punto de recogida, destino del viaje o el ingreso que puede obtener por el viaje, influyen en la decisión de cancelar la solicitud.

El presente trabajo se enfoca en analizar los datos producidos por los servicios de transporte que utilizan aplicaciones móviles, específicamente Uber y Ola Cabs. El objetivo es determinar

las tendencias de cancelaciones y agrupaciones de características parecidas mediante técnicas de minería de datos, como agrupamiento (clustering), clasificación y reglas de asociación. Analizar estos datos permite entender patrones de comportamiento y tomar decisiones para mejorar el servicio y optimizar recursos. En este contexto, el empleo de la minería de datos es importante porque las plataformas de ride-hailing producen cantidades enormes de información que necesitan técnicas avanzadas para obtener información útil.

2.2. MINERÍA DE DATOS

Según Sahu, Shrma & Gondhalakar (2011), la minería de datos es un proceso que extrae conocimiento de datos masivos, los cuales están incompletos o difusos, el cual es potencialmente útil y es desconocido por las personas.

Las técnicas de minería de datos se clasifican en aprendizaje supervisado y aprendizaje no supervisado. En este trabajo se emplearon las tareas de agrupamiento (clustering), clasificación y reglas de asociación, debido a que permiten analizar patrones ocultos. Estos algoritmos resultan ideales para conjuntos de datos generados por plataformas de transporte bajo demanda como Uber y Ola Cabs.

2.2.1. AGRUPAMIENTO (CLUSTERING)

Técnica de minería de datos no supervisada conocida como agrupamiento o clustering, tiene como propósito dividir un conjunto de datos en grupos, donde los elementos dentro del mismo grupo son similares entre sí y disimilares respecto a los elementos de otros grupos (Mamani et al., 2017). Es útil cuando no se tiene una variable objetivo en el conjunto de datos y es esencial donde la segmentación de grandes cantidades de datos son clave para las empresas.

Los tres principales tipos de agrupamiento son: jerárquico, organiza datos en estructuras de árbol (dendrogramas) y puede ser divisivo o aglomerativo; particional, lleva a cabo una sola partición en K número de grupos; basado en densidad, localiza zonas de alta densidad sin especificar K antes.

El algoritmo K-means es uno de los métodos de clustering particional más empleados en la minería de datos (Lumbreras, 2020). De acuerdo con Dunham (2002), su proceso es iterativo, el cual inicia con la selección de k centroides iniciales. Después, cada elemento del conjunto de datos es asignado al clúster cuyo centroide está más cerca mediante la distancia euclidiana como medida de similitud. Posteriormente, los centroides de cada clúster se vuelven a calcular y el procedimiento se repite hasta que se cumple una condición de convergencia, como que no haya cambios en las asignaciones o que la variación del error cuadrático sea mínima.

La eficiencia computacional es una de sus ventajas debido a que su complejidad es proporcional al número de elementos, clústeres e iteraciones realizadas. Una de sus limitaciones es que necesita definir el número de clústeres (K) previamente y la sensibilidad en la elección inicial de los centroides, lo cual afecta en la calidad del agrupamiento obtenido.

Por lo tanto, para los servicios de ride-hailing, se emplea K-means con el propósito de segmentar a los usuarios en base a sus patrones de viaje y detectar áreas de alta demanda, entre otras cosas. En un estudio sobre la movilidad urbana, Díaz (2024) usó técnicas de agrupamiento para identificar patrones de comportamiento como la detección de niveles de congestión vehicular en la ciudad de Trujillo, Perú.

2.2.2. CLASIFICACIÓN

La clasificación es una técnica de minería de datos supervisada, su objetivo es hacer un modelo que pueda asignar una clase a nuevas instancias, a partir de un conjunto de datos previamente etiquetado (Han et al., 2012). Es útil cuando se desea predecir el comportamiento de los datos, por ejemplo, determinar si un viaje será cancelado o completado a partir de sus características como la hora, zona y tiempo de espera.

Uno de los métodos de clasificación más usado son los árboles de decisión, que realizan el proceso de toma de decisiones con una estructura jerárquica de nodos y ramas. Los árboles de decisión tienen tres componentes: nodo raíz, contiene todas las instancias iniciales; nodos internos, contienen una condición sobre una variable predictora; y nodos hoja, representan la clasificación final (Breiman et al., 1984). Cada camino desde la raíz hasta una hoja forma una regla de decisión.

Los algoritmos principales para la construcción de los árboles de decisión son: CART, ID3 y C4.5 son tres métodos de clasificación. El primero emplea el índice de Gini y permite la clasificación y la regresión; el segundo se basa en la entropía y la ganancia de información para escoger divisiones; el tercero es una extensión del método ID3 que trata tanto con datos categóricos como continuos, además de tener capacidad para podar (Ulloa et al., 2022).

El algoritmo CART, por sus siglas en inglés, Classification and Regression Trees, fue utilizado en este trabajo debido a que produce árboles binarios, lo cual facilita su interpretación y análisis. Su proceso de construcción es iterativo y recursivo, este inicia con un nodo raíz que contiene todas las instancias para el entrenamiento. El algoritmo analiza todas las variables predictivas y escoge la que posibilita una división binaria óptima de los datos en cada nodo, con el objetivo de reducir al mínimo la impureza de las clases a través del índice de Gini. En cada nodo hijo, el procedimiento se repite después de la primera partición y produce nuevas

divisiones hasta que un criterio de parada, como una profundidad máxima o una cantidad mínima de instancias por nodo, se cumple. Después, es posible simplificar el árbol a través de un proceso de poda para disminuir el sobreajuste y optimizar su capacidad de generalización sobre datos no observados (Breiman et al., 1984; Han et al., 2012).

La ventaja del algoritmo CART es su interpretabilidad mediante diagramas que muestran las reglas de decisión y también permite identificar las variables más relevantes para la clasificación, lo cual es útil para analizar qué influye en la cancelación de viajes en plataformas de transporte bajo demanda. Una de sus limitaciones es que, si existen cambios en los datos de entrenamiento, aunque sean pequeños, los árboles resultantes pueden ser diferentes, lo que dificulta la reproducibilidad.

2.2.3. REGLAS DE ASOCIACIÓN

Las reglas de asociación son una técnica que permiten descubrir conocimiento en asociaciones interesantes en forma de relaciones de implicación entre valores de atributos en grandes conjuntos de datos. Esta técnica no requiere datos previamente etiquetados, por lo que descubre patrones ocultos mediante la exploración de combinaciones. Una regla de asociación tiene la forma $X \rightarrow Y$ (si X entonces Y), donde X (antecedente) y Y (consecuente) son conjuntos disjuntos de ítems. Esta regla indica que cuando ocurre X, es probable que también ocurra Y (Agrawal, Imieliński & Swami, 1993).

Para evaluar la calidad de las reglas descubiertas, se utilizan tres métricas según De Moya & Rodríguez (2003): el soporte, la confianza y el lift. El soporte indica la frecuencia de aparición de la combinación de items analizada de todas las transacciones, su fórmula es soporte($A \Rightarrow B$) = $P(A \cup B)$. La confianza es la probabilidad condicional de que ocurra Y dado que ocurrió X, su fórmula es confianza($A \Rightarrow B$) = $P(B \mid A)$, valores cerca de 1 significan que donde B casi siempre ocurre cuando está A. El lift evalúa el grado de dependencia entre los items analizados, su fórmula es lift($A \Rightarrow B$) = soporte($A \cup B$) / [soporte(A) * soporte(B)], un lift de 1 significa que A y B son independientes, si es mayor que 1 es una correlación positiva y si es menor que 1 es una correlación negativa.

El algoritmo Apriori es el más utilizado para la generación de reglas de asociación, su proceso es el siguiente: se escanea la base de datos para identificar los items más frecuentes que superen el soporte mínimo definido, después se combinan k-itemsets frecuentes mediante la unión para generar k+1 itemsets candidatos, se eliminan los candidatos que tengan algún subconjunto poco frecuente y se calcula su soporte. Se repite este proceso hasta que no se generen más itemsets frecuentes, se generan las reglas de asociación posibles con cada

itemset frecuente encontrado y se conservan las que superen el umbral de confianza mínimo establecido.

Estas reglas se pueden aplicar al análisis de datos obtenidos por Uber y Ola para descubrir patrones multivariables complejos como los patrones de cancelación, relaciones entre horarios y zonas geográficas, y el comportamiento de usuarios frecuentes. Mediante un modelo que fusionó las reglas de asociación y el clustering para estudiar los motivos de accidentes de tráfico y encontrar patrones entre variables como el vehículo involucrado y las condiciones climáticas, Shamie & Almustafa (2021) lograron detectar patrones significativos utilizando técnicas de minería de datos antes mencionadas.

2.2.4 METODOLOGÍA DE MINERÍA DE DATOS

La metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), es muy utilizada en proyectos de minería de datos debido a su perspectiva sistemática y versátil. Se compone de seis etapas: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Cada etapa comprende actividades particulares que facilitan la ejecución del proyecto de manera ordenada. Es relevante señalar que este proceso puede ser iterativo en caso de necesitar perfeccionar los resultados (Chapman et al., 2000).

La primera fase es la comprensión del negocio, en esta fase se definen los objetivos del proyecto desde una perspectiva de negocio. En la fase de comprensión de los datos se recolectan los datos iniciales, se describen y se exploran, identificando los problemas que puedan tener los datos. Una vez que se analizaron los datos, se seleccionan los datos relevantes y se limpian los que tengan valores faltantes o que tengan valores atípicos, en la preparación de los datos puede que se tenga que crear nuevas variables derivadas, integrar datos de múltiples fuentes o formatear los datos según los requerimientos. Posteriormente, se escogen las técnicas de modelado apropiadas al proyecto y se diseñan estrategias de evaluación, se construye el modelo y este se evalúa según las métricas definidas. Después, se evalúan los resultados respecto a los objetivos de negocio y se determinan los próximos pasos, si se despliega o si requiere una iteración adicional. Para el despliegue, se planifica y se produce el reporte final.

En el presente trabajo, la metodología CRISP-DM permitió estructurar el análisis de los datos de viajes y cancelaciones de las plataformas de Uber y Ola Cabs con una correcta preparación del conjunto de datos y la aplicación de técnicas de agrupamiento, clasificación y reglas de asociación. Asimismo, se evaluaron los modelos obtenidos antes de usarlos e interpretar sus resultados.

UNIDAD III. MÉTODO DE DESARROLLO

3.1 DESCRIPCIÓN DE DATOS

El conjunto de datos seleccionado, Booking.csv, muestra información con relación a los viajes realizados dentro las plataformas de transporte de Uber y Ola del mes de julio del 2024, contiene 103,024 registros y 20 columnas. Los ID's de las solicitudes y de los clientes fueron modificados para mantener la confidencialidad.

A continuación, en la Tabla 1 se describe cada variable del conjunto de datos.

Tabla 1. Descripción de las variables

No	Nombre	Significado	Tipo de dato	Dominio de los valores
1	Date	Fecha y hora en que se realizó la solicitud del viaje	Fecha	DD/MM/AAAA HH:MM
2	Time	Hora que se realizó la solicitud del viaje	Hora	00:00:00 a 23:59:59
3	Booking_ID	Identificador único asignado a cada viaje registrado en la plataforma	Categórico (Identificador)	Valores alfanuméricos únicos
4	Booking_Status	Estado final del viaje dentro del sistema	Categórico nominal	Completado, cancelado por el cliente o por el conductor
5	Customer_ID	Identificador único del cliente que solicitó el viaje	Categórico (Identificador)	Valores alfanuméricos únicos
6	Vehicle_Type	Tipo de vehículo asignado al viaje	Categórico nominal	Auto, Prime Sedan, Mini, Bike, eBike, Prime SUV, Prime Plus
7	Pickup_Location	Ubicación de origen del viaje	Categórico nominal	Nombres o identificadores de zonas y ubicaciones
8	Drop_Location	Ubicación de destino del viaje	Categórico nominal	Nombres de zonas o ubicaciones
9	V_TAT (Vehicle Turn Around Time)	Tiempo que tarda para que un conductor acepte el viaje	Numérico continuo	Valores positivos expresados en segundos
10	C_TAT (Customer Turn Around Time)	Tiempo que tarda el cliente en abordar el vehículo después de su llegada	Numérico continuo	Valores positivos en segundos
11	Canceled_Rides_by _Customer	Razón del viaje cancelado por el cliente	Categórico nominal	Descripciones textuales
12	Canceled_Rides_by _Driver	Razon del viaje cancelado por el conductor	Categórico nominal	Descripciones textuales
13	Incomplete_Rides	Viaje incompleto	Categórico nominal	Si / No

14	Incomplete_Rides_ Reason	Motivo por el que el viaje fue cancelado	Categórico nominal	Razones predefinidas por la plataforma
15	Booking_Value	Valor monetario total del viaje	Numérico continuo	Positivos mayores a cero
16	Payment_Method	Método de pago utilizado en el viaje	Categórico nominal	Efectivo, tarjeta, billetera digital u otros
17	Ride_Distance	Distancia total recorrida durante el viaje	Numérico continuo	Valores positivos, expresados en kilómetros
18	Driver_Ratings	Calificación otorgada al conductor por el cliente	Numérico continuo	Valores entre uno y cinco
19	Customer_Rating	Calificación otorgada el cliente por el conductor	Numérico continuo	Valores entre uno y cinco
20	Vehicle Images	Columna con error de importación		

Nota: Elaboración propia.

La variable Vehicle Images tiene valores inválidos, ya que el conjunto de datos está en un archivo CSV y no acepta imágenes como valores para los registros, por lo que será eliminada en la fase de tratamiento de datos.

Ahora, se mostrará el análisis exploratorio de cada variable categórica y numérica, excluyendo Booking_ID, Customer_ID, Date y Vehicle Images en el análisis con gráficas.

En la Figura 1 se muestra que las variables Booking_Status, Vehicle_Type, Booking_Value y Ride_Distance no presentan valores nulos. Las variables sobre el rendimiento y satisfacción de cada viaje tienen aproximadamente un 38% de valores nulos, estas son V_TAT, C_TAT, Driver_Ratings y Custoner_Ratings. Además, las variables Canceled_Rides_by_Customer y Canceled_Rides_by_Driver presentan aproximadamente un 89% y 82% de valores nulos respectivamente. La variable de Incomplete_Rides_Reason es la que tiene más valores nulos con un 96.19%.

Variable	Tipo	Total Registros	No Nulos	Nulos	% Nulos
Date	object	103024	103024	0	0.00
Time	object	103024	103024	0	0.00
Booking_ID	object	103024	103024	0	0.00
Booking_Status	object	103024	103024	0	0.00
Customer_ID	object	103024	103024	0	0.00
Vehicle_Type	object	103024	103024	0	0.00
Pickup_Location	object	103024	103024	0	0.00
Drop_Location	object	103024	103024	0	0.00
V_TAT	float64	103024	63967	39057	37.91
C_TAT	float64	103024	63967	39057	37.91
Canceled_Rides_by_Customer	object	103024	10499	92525	89.81
Canceled_Rides_by_Driver	object	103024	18434	84590	82.11
Incomplete_Rides	object	103024	63967	39057	37.91
Incomplete_Rides_Reason	object	103024	3926	99098	96.19
Booking_Value	int64	103024	103024	0	0.00
Payment_Method	object	103024	63967	39057	37.91
Ride_Distance	int64	103024	103024	0	0.00
Driver_Ratings	float64	103024	63967	39057	37.91
Customer_Rating	float64	103024	63967	39057	37.91

Figura 1. Porcentaje de nulos por variable

Para la variable Time, podemos observar que todas las horas tienen una cantidad de reservas similares, por lo que no hay una hora en específico que haya más reservas.



Figura 2. Cantidad de reservas por hora

Para la variable Booking_Status se tiene que la mayoría de los registros de viajes fueron completados, mientras que los que fueron cancelados por el conductor son alrededor de 18000 viajes. Los registros que fueron cancelados por los clientes y en los que no se encontró un conductor tienen aproximadamente la misma cantidad.

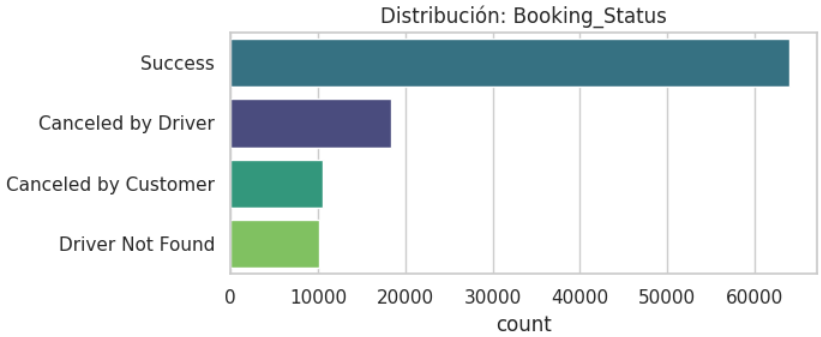


Figura 3. Estado final de los viajes

Para la variable Vehicle_Type, se muestra en la Figura 4 que el tipo de vehículo Prime Sedan tuvo ligeramente más viajes. Sin embargo, el resto de los vehículos tienen un número similar de viajes, lo que refleja la diversidad de preferencias de los clientes. El tipo de vehículo Mini tiene menos viajes registrados que el resto de los vehículos.

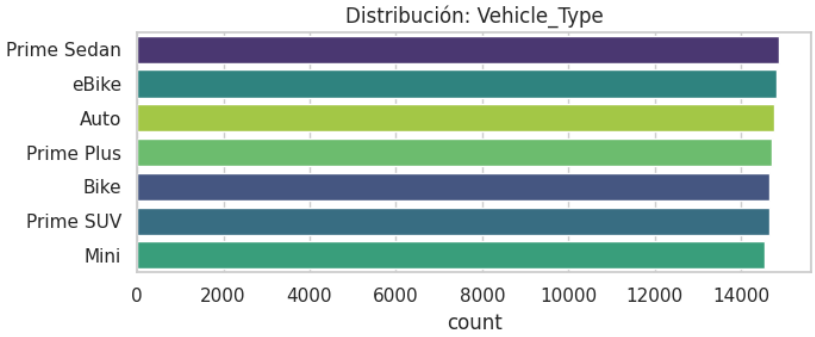


Figura 4. Cantidad de viajes por tipo de vehículo

Para la variable Pickup_Location, se tienen aproximadamente 50 ubicaciones diferentes de origen de viajes. Se observa que Banashankari fue el lugar de origen que más frecuencia tuvo, mientras que Rajajinagar fue el lugar de origen con menos frecuencia.

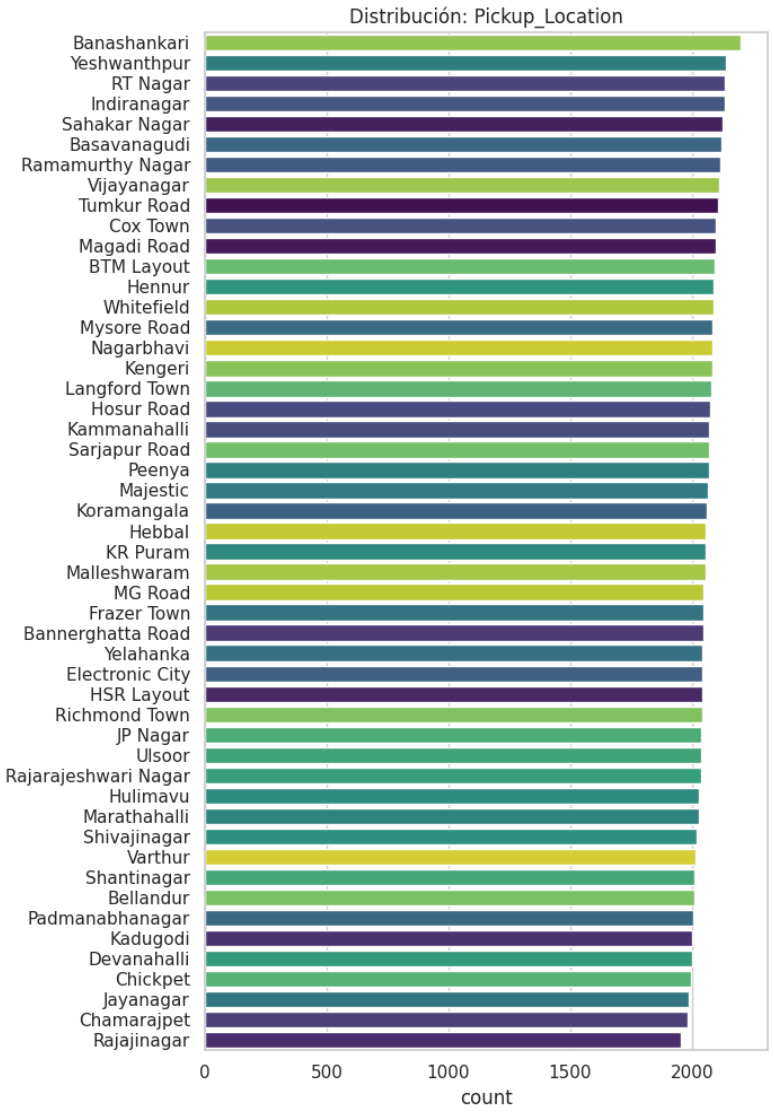


Figura 5. Ubicación de origen del viaje

Para la variable Drop_Location, se tiene que Peenya fue el lugar de destino con más frecuencia mientras que Whitefield tuvo menos frecuencia que el resto de los lugares.

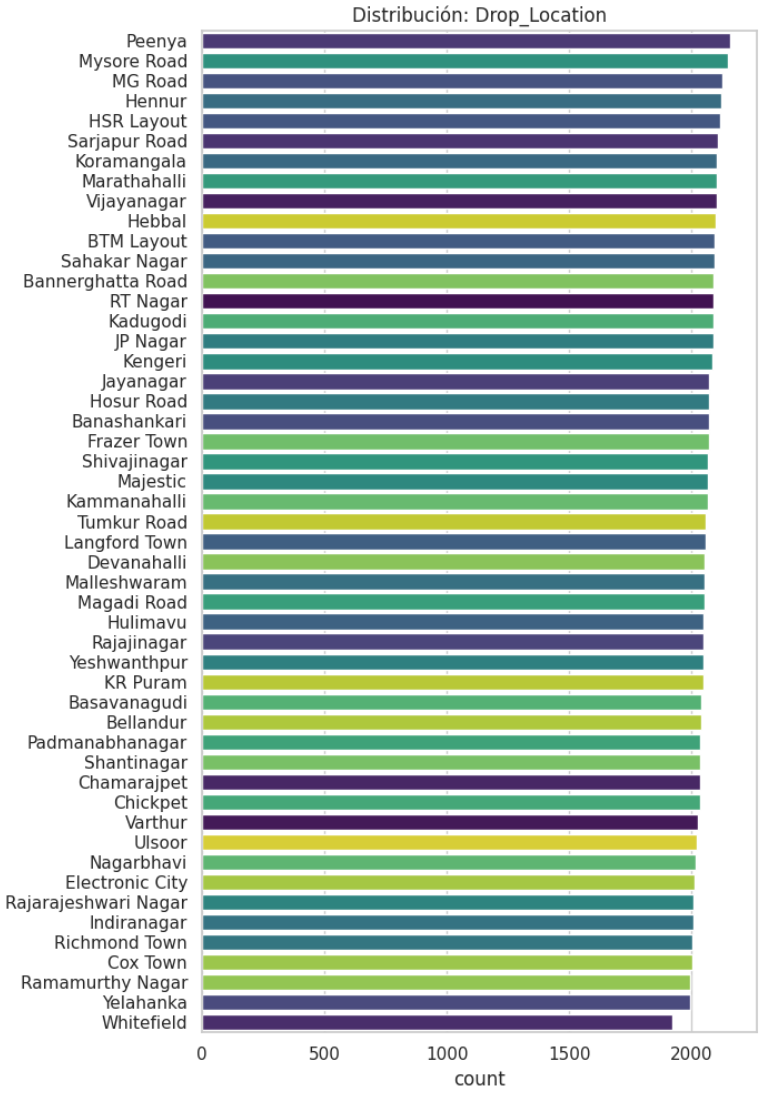


Figura 6. Ubicación de destino de viajes

Para la variable Canceled_Rides_by_Customer, la mayoría de los registros son nulos, lo que significa que la mayoría de los viajes fueron completados con éxito y no fueron cancelados. Sin embargo, de los viajes que fueron cancelados por el cliente, la razón más frecuente fue porque el conductor no se movía hacia la ubicación de partida del viaje, mientras que la razón con menos frecuencia fue que pusieron la dirección incorrecta.

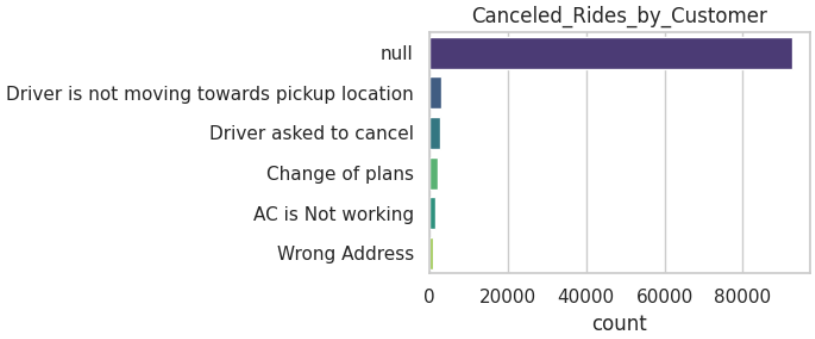


Figura 7. Motivo de cancelación de viaje por el cliente

Para la variable Canceled_Rides_by_Driver, la mayoría de los registros son nulos, lo que significa que la mayoría de los viajes fueron completados con éxito y no fueron cancelados. No obstante, los viajes que fueron cancelados por el conductor, la mayoría de las veces fue por problemas personales y problemas relacionados con el vehículo. La razón menos frecuente fue porque había más personas de las permitidas por parte del cliente.

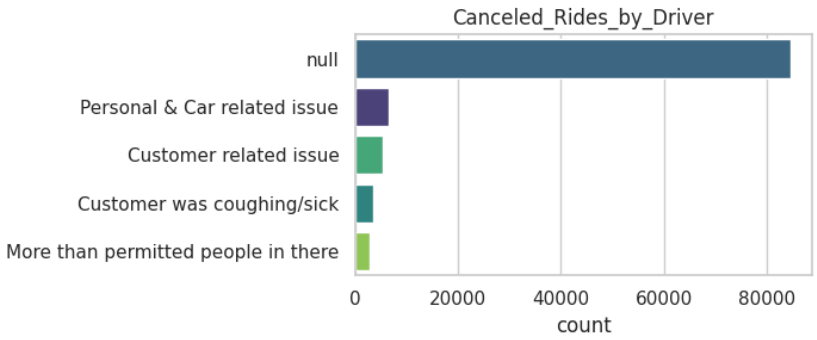


Figura 8. Motivo de cancelación de viaje por el conductor

Para la variable Incomplete_Rides, aproximadamente 60000 registros fueron No, lo que significa que el trayecto del viaje se completó con éxito. Para los registros con valores nulos, son viajes que no avanzaron a la fase de ejecución, es decir, que se cancelaron o no se encontró un conductor para ese viaje; por lo tanto, no existe viaje para clasificarse como incompleto y se deja como nulo, aunque podría ser tratado como “No aplica”.

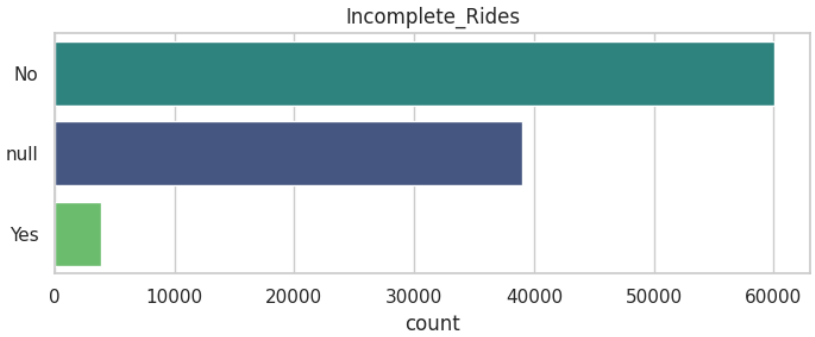


Figura 9. Frecuencia de viajes incompletos

Para la variable Incomplete_Rides_Reason, casi 100000 registros son nulos, lo que significa que estos viajes fueron completados o porque ni si quiera se inició el viaje. Para los viajes que sí fueron incompletos, la mayor razón fue por demanda del cliente, seguido de daño del vehículo y con menos frecuencia, otro problema.

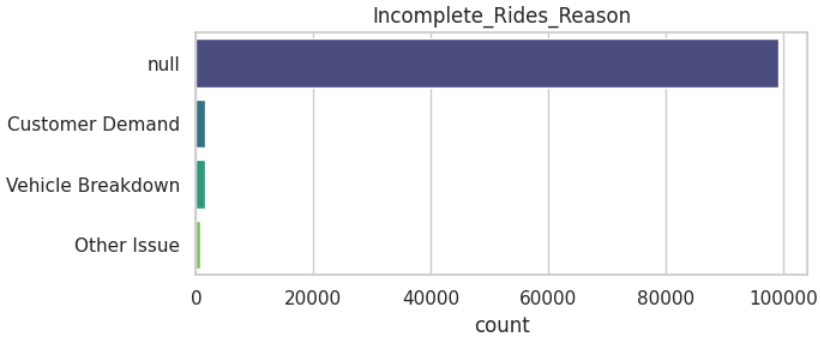


Figura 10. Frecuencia de razones de viajes incompletos

Para la variable Payment_Method, se tiene un alto número de valores nulos que corresponden a los viajes que no fueron exitosos por cancelaciones o porque no se encontró un conductor. Sin embargo, los viajes que fueron completados, la mayoría usó como método de pago el efectivo, mientras que el método menos frecuente fue la tarjeta de débito. El método de pago UPI es un sistema popular de pago digital en la India.

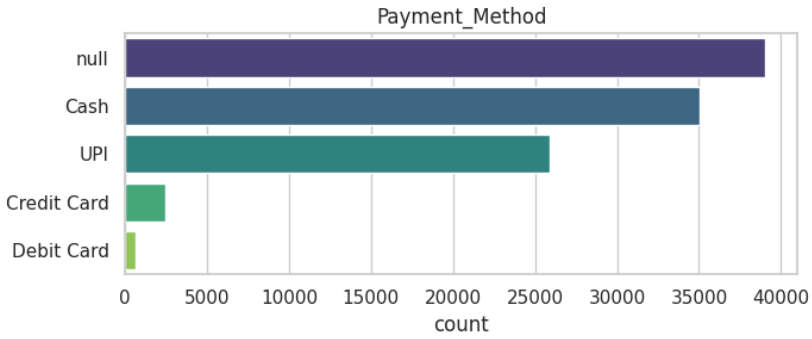


Figura 11. Frecuencia de métodos de pago

Para V_TAT, de los viajes que fueron completados, la mediana del tiempo que espera el cliente para que un conductor acepte su viaje es de 168 segundos, el mínimo es de 35 segundos y el máximo es de 308 segundos, sin valores atípicos.

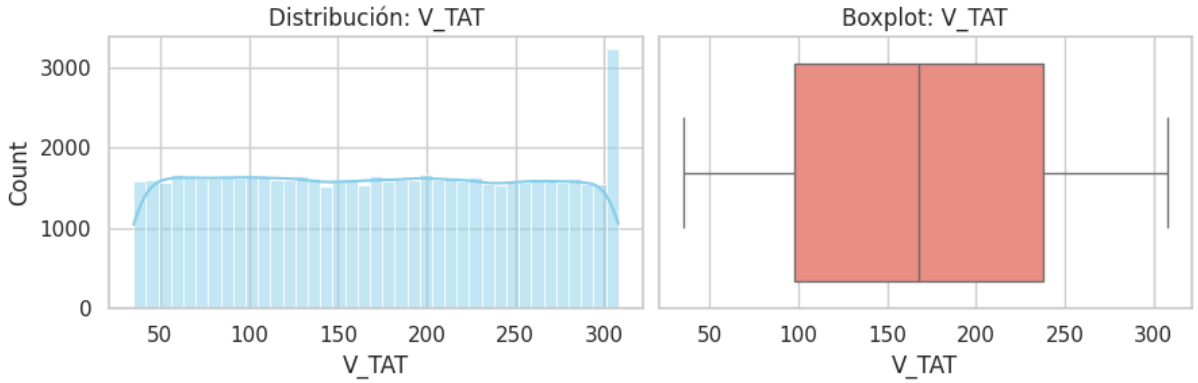


Figura 12. Tiempo que tarda para que un conductor acepte el viaje

Para la variable C_TAT, se muestra que de los viajes que fueron completados, la mediana del tiempo que tardó el cliente en abordar el vehículo después de su llegada es de 85 segundos,

con un mínimo de 25 segundos y un máximo de 145 segundos, sin valores atípicos. El histograma muestra una frecuencia elevada entre 20 y 80 segundos, lo que significa que los clientes suelen abordar rápido el vehículo.

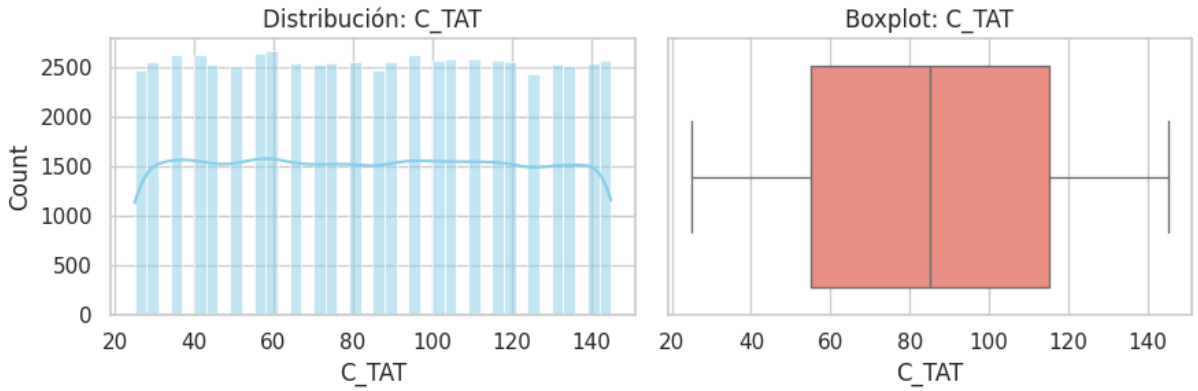


Figura 13. Tiempo que tarda el cliente en abordar el vehículo después de su llegada

Para la variable Booking_Value, la mediana del costo de los viajes es de 385 rupias indias (se asume esta moneda por los lugares de origen de los viajes), el mínimo de 100 rupias y el máximo de 2999 rupias, con muchos valores atípicos. El histograma muestra una concentración en valores entre 0 a 500 rupias, con una gran disminución en valores más altos. Esto significa que la mayoría de los viajes fueron económicos.

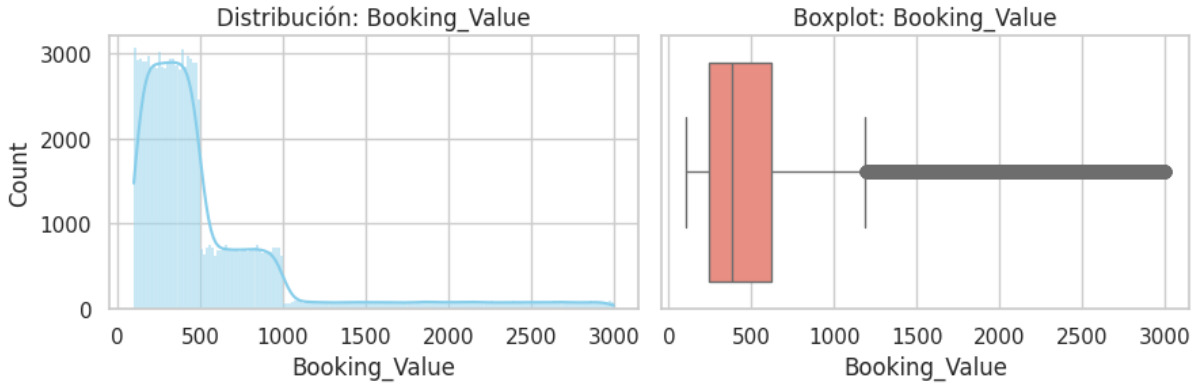


Figura 14. Valor monetario total de los viajes

Para Ride_Distance, la mediana de la distancia recorrida durante los viajes es de 21 kilómetros, con un mínimo de 1 kilómetro y el máximo de 49 kilómetros, con una proporción a valores extremos en el diagrama de caja y bigote. El histograma muestra una alta concentración en distancias cortas.

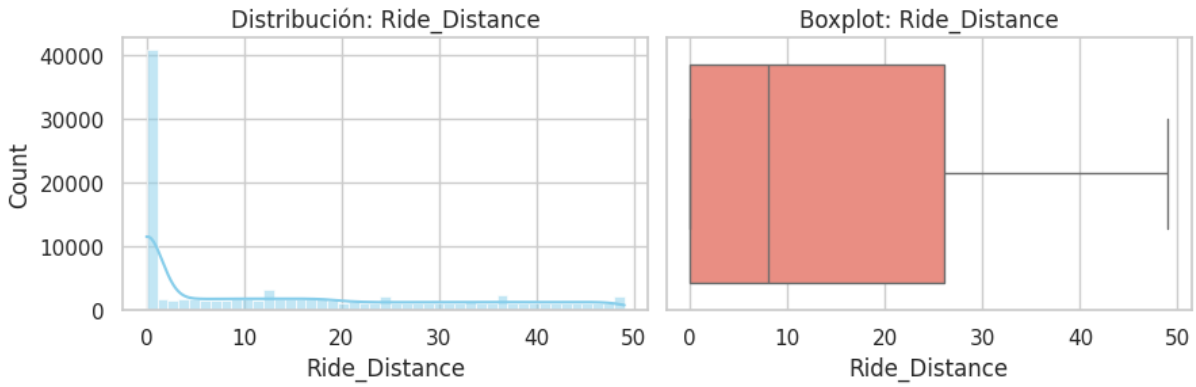


Figura 15. Distancia total recorrida durante los viajes

Para Driver_Ratings, se tiene una mediana de 4 de calificación para el conductor de parte del cliente, con un mínimo de 3 y un máximo de 5 (escala de 3 a 5), no se tiene valores atípicos. El histograma muestra una distribución aproximadamente normal con picos en 3.5 y 4.5.

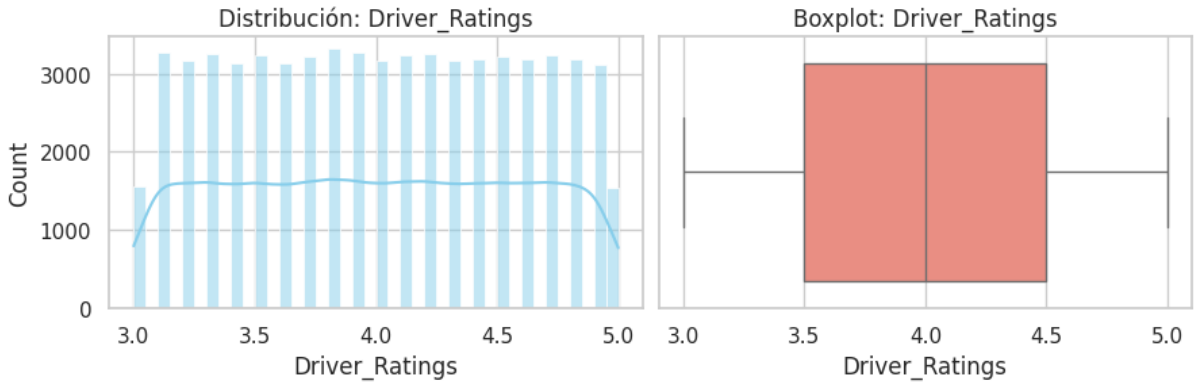


Figura 16. Calificación otorgada al conductor por el cliente

Para la variable Customer_Rating, se tiene que la mediana está en 4 de calificación para el cliente por parte del conductor, con un mínimo de 3 y máximo de 5, sin valores atípicos, similar a Driver_Ratings. El histograma muestra un resultado similar de distribución normal con picos en 4, lo que demuestra evaluaciones similares entre clientes y conductores.

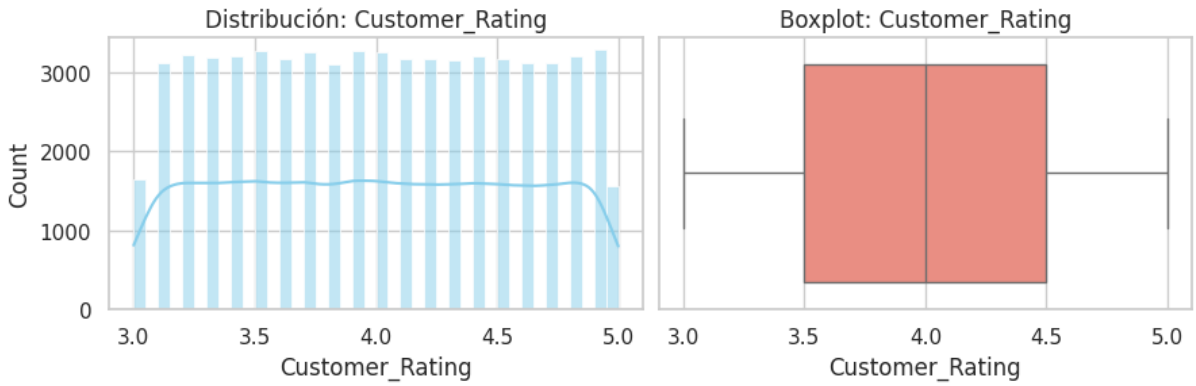


Figura 17. Calificación otorgada al cliente por el conductor

Para el desarrollo del proyecto se aplicaron tres diferentes algoritmos para el mismo conjunto de datos, esto significa que, para cada uno, la selección de los datos fue diferente, tanto en el

tipo de variables como en la forma en que los datos deben ser tratados. Por lo cual el procesamiento de las variables fue distinto para cada modelo.

Se aplicó el algoritmo de agrupamiento donde se utilizaron exclusivamente variables numéricas, ya que este se basa en el cálculo de distancias entre los registros. Asimismo, se aplicaron reglas de asociación, donde en este caso la selección de las variables fue aquellas categóricas, con el objetivo de identificar relaciones frecuentes entre características de los viajes, como estados, tipos de servicios o rangos de valores. Finalmente, el algoritmo de clasificación, se definió una variable objetivo con el fin de predecir un comportamiento específico del viaje, como el estado del servicio o la ocurrencia de cancelaciones.

De esta forma se nos permitió adaptar el conjunto de datos a las características particulares, asegurando un funcionamiento adecuado de los algoritmos.

3.2 DESCRIPCIÓN DEL CONJUNTO DE DATOS

Previo a la aplicación de los modelos de minería de datos, se realizó un análisis exploratorio del conjunto de datos con el fin de describir sus principales características y relación entre variables. Para ello, se definieron consultas que permiten analizar la distribución del estado de las reservas, su relación con el tipo de vehículo, la ubicación, el método de pago y variables numéricas relevantes. Este análisis facilita la identificación de patrones y dependencias que sirven como base para las etapas posteriores del modelo.

- **Consulta 1: Distribución del estado de la reserva**

Descripción: Se analizó la distribución de las reservas según su estado final para identificar la proporción de viajes completados y no completados.
Resultados:

Row ID	S Booking_Status	I Count...
Row0	Canceled by Customer	2124
Row1	Canceled by Driver	3628
Row2	Driver Not Found	2008
Row3	Success	12844

Figura 18. Resultado consulta 1

Interpretación: La mayoría de las reservas del conjunto de datos se completan de manera exitosa, lo que indica que el sistema de los viajes funciona de manera eficiente generalmente. Sin embargo, existe una proporción relevante de viajes no completados, principalmente debido a cancelaciones.
Entre los viajes cancelados, las cancelaciones por parte del conductor son más frecuentes, superando las cancelaciones del cliente.

El estado “Driver Not Found” también representa una cantidad significativa, lo que sugiere problemas de disponibilidad de conductores en ciertos casos.
Esto evidencia que no todas las fallas están relacionadas con el cliente, sino que una parte importante está asociada a la operación del sistema.

- **Consulta 2: Estado de la reserva por tipo de vehículo**

Descripción: Se examinó la relación entre el estado de la reserva y el tipo de vehículo utilizado, con el objetivo de identificar si ciertos tipos de vehículos presentan mayor tendencia a viajes exitosos y cancelados.
Resultado:

Row ID	Booking_Status	Vehicle...	Count...
Row21	Success	Auto	1873
Row22	Success	Bike	1846
Row23	Success	Mini	1724
Row24	Success	Prime Plus	1856
Row25	Success	Prime SUV	1833
Row26	Success	Prime Sedan	1843
Row27	Success	eBike	1869
Row14	Driver Not Found	Auto	274
Row15	Driver Not Found	Bike	278
Row16	Driver Not Found	Mini	264
Row17	Driver Not Found	Prime Plus	308
Row18	Driver Not Found	Prime SUV	338
Row19	Driver Not Found	Prime Sedan	290
Row20	Driver Not Found	eBike	256
Row7	Canceled by Driver	Auto	534
Row8	Canceled by Driver	Bike	518
Row9	Canceled by Driver	Mini	522
Row10	Canceled by Driver	Prime Plus	521
Row11	Canceled by Driver	Prime SUV	501
Row12	Canceled by Driver	Prime Sedan	499
Row13	Canceled by Driver	eBike	533
Row0	Canceled by Customer	Auto	287
Row1	Canceled by Customer	Bike	319
Row2	Canceled by Customer	Mini	304
Row3	Canceled by Customer	Prime Plus	301
Row4	Canceled by Customer	Prime SUV	294
Row5	Canceled by Customer	Prime Sedan	327
Row6	Canceled by Customer	eBike	292

Figura 19. Resultado consulta 2

Interpretación: Los viajes exitosos (Success) se distribuyen de forma bastante uniforme entre los distintos tipos de vehículo: Auto, eBike, Prime Plus, Prime Sedan, Prime SUV y Bike que presentan volúmenes similares. No existe un tipo de vehículo claramente dominante en los viajes exitosos. Esto sugiere que todos los tipos de vehículos son igualmente viables para completar viajes con éxito.
En los casos donde no se encontró el conductor (Driver Not Found) los valores son significativamente menores que los viajes exitosos, Prime SUV y Prime Plus presentan ligeramente más casos de Driver Not Found. Esto puede indicar que los vehículos de gama más alta o con menor disponibilidad tienen más problemas de asignación de conductor.

En las cancelaciones por el conductor (Canceled by Driver) los valores son muy similares entre tipos de vehículo, por lo que las cancelaciones por el conductor no parecen depender fuertemente del tipo de vehículo, sino más bien de factores operativos o contextuales.
De igual forma, las cancelaciones por el cliente (Canceled by Customer) presentan una distribución homogénea entre los tipos de vehículo, lo que refuerza la idea de que el tipo de vehículo no es un factor decisivo en la cancelación por parte del cliente.

- **Consulta 3: Ubicaciones con más cancelaciones**

Descripción: Se identificaron las zonas de recogida con mayor frecuencia de cancelaciones, con el propósito de detectar áreas geográficas donde los viajes presentan mayor probabilidad de no cancelarse.
Resultado:

Row ID	Pickup_...	Count...
Row14	Hosur Road	181
Row16	Indiranagar	181
Row49	Yeshwanthpur	181
Row43	Tumkur Road	175
Row10	Frazer Town	174
Row34	RT Nagar	172
Row39	Sahakar Nagar	170
Row24	Langford To...	169
Row42	Shivajinagar	164
Row2	Bannerghatt...	163
Row46	Vijayanagar	163
Row47	Whitefield	163
Row1	Banashankari	162
Row6	Chickpet	162
Row17	JP Nagar	161
Row37	Ramamurthy...	161
Row18	Jayanagar	160
Row28	Malleshwaram	160
Row41	Shantinagar	160
Row26	Magadi Road	159
Row21	Kammanahalli	158
Row29	Marathahalli	158
Row36	Rajarajeshw...	158
Row22	Kengeri	157
Row27	Majestic	157
Row30	Mysore Road	157
Row11	HSR Layout	156
Row35	Rajajinagar	155
Row19	KR Puram	151
Row5	Chamarajpet	150
Row23	Koramangala	150
Row31	Nagarbhavi	150
Row32	Padmanabh...	150
Row33	Peenya	150
Row3	Basavanagudi	149
Row8	Devanahalli	149
Row48	Yelahanka	149
Row9	Electronic City	147

Figura 20. Resultado consulta 3

Row20	Kadugodi	146
Row25	MG Road	146
Row15	Hulimavu	144
Row0	BTM Layout	142
Row4	Bellandur	140
Row40	Sarjapur Road	140
Row38	Richmond T...	139
Row12	Hebbal	138
Row45	Varthur	138
Row44	Ulsoor	134
Row7	Cox Town	131
Row13	Hennur	130

Figura 21. Continuación resultado consulta 3

Interpretación: El análisis de las ubicaciones de recogida con mayor número de cancelaciones muestra que zonas como Hosur Road, Indiranagar, Yeshwanthpur, Tumkur Road, Frazer Town, entre otras, destacan como puntos críticos donde la probabilidad de cancelación es ligeramente mayor. Aun así, la mayoría de las zonas presentan valores entre 140 y 165 cancelaciones y no existe una diferencia extrema entre ubicaciones, lo que indica que las cancelaciones están relativamente distribuidas en la ciudad y que no hay una zona problemática, sino varias con niveles moderadamente altos. Las zonas con mayor número de cancelaciones suelen corresponder a áreas de alta demanda o con mayor congestión, lo cual puede dificultar la asignación de conductores y aumentar la probabilidad de cancelación.

- **Consulta 4: Métodos de pago y su relación con el estado**

Descripción: Se analizó la relación entre el método de pago y el estado de la reserva, con el fin de determinar si la disponibilidad del método de pago está asociada al éxito o cancelación del viaje.

Resultado:

Row ID	S Booking_Status	S Payment_M...	I Count...
Row0	Canceled by Customer	No_Payment_Info	2124
Row1	Canceled by Driver	No_Payment_Info	3628
Row2	Driver Not Found	No_Payment_Info	2008
Row3	Success	Cash	7017
Row4	Success	Credit Card	507
Row5	Success	Debit Card	130
Row6	Success	UPI	5190

Figura 22. Resultado consulta 4

Interpretación: En el caso de los viajes no completados, el método de pago registrado es “No_Payment_Info” en todos los casos, lo que confirma que cuando un viaje no se completa, el pago no llega a procesarse por lo que no existe información de método de pago.

En los viajes exitosos (Success) si se registra un método de pago y se puede observar que el efectivo (Cash) y UPI, son por mucho, los métodos de pago más utilizados.

- **Consulta 5: Viajes incompletos y sus razones**

Descripción: Se evaluaron las principales razones por las cuales los viajes no se completan con el objetivo de identificar las causas más frecuentes de incompletitud del servicio.
Resultado:

Row ID	S Incomplete_Rides_Reason	I Count...
Row0	Customer Demand	323
Row1	Other Issue	144
Row2	Vehicle Breakdown	316

Figura 23. Resultado consulta 5

Interpretación: Se puede observar que Customer Demand es la causa más frecuente, lo que indica que muchos viajes incompletos se deben a decisiones o cambios por parte del cliente. Vehicle Breakdown presenta un valor muy cercano, lo que señala que problemas mecánicos o técnicos de los vehículos representan una causa crítica de interrupción del servicio.
Other Issue agrupa un número menor de casos, funcionando como una categoría residual para eventos menos comunes o no clasificados.

- **Consulta 6: Análisis descriptivo de las variables numéricas**

Descripción: Se realizó un análisis descriptivo de las principales variables numéricas del conjunto de datos, considerando medidas estadísticas como mínimo, máximo, media y desviación estándar, para comprender su comportamiento general y variabilidad.
Resultado:

Name	Minimum	Maximum	Mean	Mean Absolute Deviation	Standard Deviation
V_TAT	35	308	169.984	70.444	81.116
C_TAT	25	145	85.078	31.274	36.165
Booking_Value	100	2,999	545.063	349.059	539.06
Ride_Distance	0	49	14.186	13.592	15.717
Driver_Ratings	3	5	3.991	0.498	0.577
Customer_Rating	3	5	4.001	0.499	0.579

Figura 24. Resultado consulta 6

Interpretación: En la variable V_TAT (Vehicle Turn Around Time) se indica que existe una alta variabilidad en el tiempo de respuesta del vehículo, lo que sugiere que factores como la ubicación, disponibilidad o tipo de vehículo influyen considerablemente en este indicador.
En la variable C_TAT (Customer Turn Around Time) se puede observar que el tiempo de respuesta del cliente es menor y más estable que el del vehículo, lo que indica que los mayores retrasos del proceso están asociados principalmente a factores operativos del sistema.

Booking_Value, el valor de los viajes presenta una dispersión muy elevada, con valores extremos altos. Esto indica una distribución sesgada, donde la mayoría de los viajes son de bajo o mediano costo, pero existen viajes significativamente más caros.
Ride_Distance, se puede observar que la distancia promedio es relativamente corta, aunque la desviación estándar cercana a la media indica una gran heterogeneidad en las longitudes de los viajes.
Driver_Ratings, las calificaciones de los conductores son altas y poco dispersas, lo que sugiere una evaluación generalmente positiva y consistente.
Customer_Raiting, de manera similar a las calificaciones de conductores, las calificaciones de los clientes son altas y estables, indicando un buen nivel de satisfacción general.

- **Consulta 7: Valor del viaje según el estado**

Descripción: Se analizó el valor económico de los viajes en función del estado de la reserva, con el objetivo de evaluar si el costo del viaje influye en la probabilidad de cancelación o finalización exitosa.
Resultado:

Row ID	S Booking_Status	D Median...	D Mean...
Row0	Canceled by Customer	373	526.264
Row1	Canceled by Driver	382	552.725
Row2	Driver Not Found	397	551.194
Row3	Success	?	545.049

Figura 25. Resultado consulta 7

Interpretación: Acerca del valor promedio del viaje, los valores son muy similares entre todos los estados, con diferencias relativamente pequeñas, esto indica que el valor económico del viaje no es un factor determinante para que un viaje sea cancelado o completado, es decir, tanto viajes baratos como caros tienen probabilidades similares de cancelarse.
Mediana del valor del viaje, para los viajes cancelados esta se encuentra entre 373 y 397. La diferencia entre media y mediana sugiere una distribución sesgada, con algunos viajes del alto valor elevando el promedio.

- **Consulta 8: Distancia promedio por estado**

Descripción: Se examinó la distancia promedio recorrida en los viajes de acuerdo con el estado de la reserva, con el propósito de determinar si la distancia del trayecto está relacionada con la cancelación del viaje.
Resultado:

Row ID	Booking_Status	Mean...
Row0	Canceled by Customer	0
Row1	Canceled by Driver	0
Row2	Driver Not Found	0
Row3	Success	22.757

Figura 26. Resultado consulta 8

Interpretación: El valor 0 en los viajes cancelados significa que la distancia no se registra cuando el viaje no se completa. Se puede inferir que la distancia no puede influir en la cancelación porque no existe antes de que el viaje ocurra lo que confirma que la variable Ride_Distance es estructuralmente dependiente del estado de reserva.

- **Consulta 9: Combinaciones de ubicación de recogida y destino**

Descripción: Se identificaron las combinaciones más frecuentes de ubicación de recogida y destino, con el objetivo de analizar los patrones de movilidad y detectar rutas con mayor número de viajes y cancelaciones.

Resultado:

Row ID	Booking...	Pickup_Locat...	Drop_L...	Count(...
Row1858	Success	Ramamurthy Nagar	Kadugodi	15
Row215	Success	Bellandur	Indiranagar	14
Row1171	Success	Koramangala	Malleshwaram	14
Row22	Success	BTM Layout	Kengeri	13
Row713	Success	Hosur Road	JP Nagar	13
Row1664	Success	Peenya	Koramangala	13
Row430	Success	Devanahalli	Peenya	12
Row747	Success	Hulimavu	Banashankari	12
Row809	Success	Indiranagar	Hosur Road	12
Row1134	Success	Kengeri	Shantinagar	12
Row1251	Success	MG Road	Devanahalli	12
Row1553	Success	Nagarbhavi	HSR Layout	12
Row1822	Success	Rajarajeshwari N...	RT Nagar	12
Row1838	Success	Ramamurthy Nagar	BTM Layout	12
Row2324	Success	Vijayanagar	Sarjapur Road	12
Row53	Success	Banashankari	Basavanagudi	11
Row159	Success	Basavanagudi	Frazer Town	11
Row229	Success	Bellandur	Mysore Road	11
Row259	Success	Chamarajpet	Frazer Town	11
Row287	Success	Chamarajpet	Richmond T...	11
Row368	Success	Cox Town	KR Puram	11
Row536	Success	Frazer Town	Sarjapur Road	11
Row562	Success	HSR Layout	Indiranagar	11

Figura 27. Resultado consulta 9

Interpretación: El análisis de las combinaciones de ubicación de recogida y destino muestra que no existe una única ruta dominante, sino múltiples trayectos con frecuencias similares. Las rutas más frecuentes corresponden a corredores urbanos comunes entre zonas

residenciales y comerciales. Este comportamiento indica una alta diversidad de trayectos dentro del sistema. Asimismo, las rutas con mayor número de viajes tienden a concentrar más eventos simplemente por volumen, sin que ello implique necesariamente una mayor propensión a cancelaciones.

- **Consulta 10: Métodos de pago por tipo de vehículo y estado**

Descripción: Se analizó la relación entre el método de pago, el tipo de vehículo y el estado de la reserva, con el fin de identificar patrones de uso de los métodos de pago según las características del viaje.

Resultado:

Row ID	Booking_Status	Vehicle...	Payment_M...	Count...
Row37	Success	Prime SUV	Cash	1063
Row21	Success	Auto	Cash	1043
Row45	Success	eBike	Cash	1024
Row33	Success	Prime Plus	Cash	1023
Row25	Success	Bike	Cash	980
Row41	Success	Prime Sedan	Cash	953
Row29	Success	Mini	Cash	931
Row44	Success	Prime Sedan	UPI	803
Row28	Success	Bike	UPI	786
Row48	Success	eBike	UPI	753
Row36	Success	Prime Plus	UPI	745
Row24	Success	Auto	UPI	733
Row32	Success	Mini	UPI	707
Row40	Success	Prime SUV	UPI	663
Row7	Canceled by Driver	Auto	No_Payment_Info	534
Row13	Canceled by Driver	eBike	No_Payment_Info	533
Row9	Canceled by Driver	Mini	No_Payment_Info	522
Row10	Canceled by Driver	Prime Plus	No_Payment_Info	521
Row8	Canceled by Driver	Bike	No_Payment_Info	518
Row11	Canceled by Driver	Prime SUV	No_Payment_Info	501
Row12	Canceled by Driver	Prime Sedan	No_Payment_Info	499
Row18	Driver Not Found	Prime SUV	No_Payment_Info	338
Row5	Canceled by Customer	Prime Sedan	No_Payment_Info	327
Row1	Canceled by Customer	Bike	No_Payment_Info	319
Row17	Driver Not Found	Prime Plus	No_Payment_Info	308
Row2	Canceled by Customer	Mini	No_Payment_Info	304
Row3	Canceled by Customer	Prime Plus	No_Payment_Info	301
Row4	Canceled by Customer	Prime SUV	No_Payment_Info	294
Row6	Canceled by Customer	eBike	No_Payment_Info	292
Row19	Driver Not Found	Prime Sedan	No_Payment_Info	290
Row0	Canceled by Customer	Auto	No_Payment_Info	287
Row15	Driver Not Found	Bike	No_Payment_Info	278
Row14	Driver Not Found	Auto	No_Payment_Info	274
Row16	Driver Not Found	Mini	No_Payment_Info	264
Row20	Driver Not Found	eBike	No_Payment_Info	256
Row38	Success	Prime SUV	Credit Card	89
Row22	Success	Auto	Credit Card	79
Row34	Success	Prime Plus	Credit Card	75

Figura 28. Resultado consulta 10

Interpretación: En primer lugar, los viajes exitosos (Success) se concentran principalmente en los métodos de pago Cash y UPI, independientemente del tipo de vehículo. Vehículos como Prime SUV, Auto, eBike, Prime Plus y Bike presentan altos conteos cuando el pago es en efectivo, lo que indica que Cash es el método de pago predominante en los viajes completados. UPI aparece como la segunda opción más utilizada en viajes exitosos, lo que sugiere una adopción relevante de pagos digitales, aunque aún por debajo del efectivo.
En contraste, en los estados Canceled by Driver, Canceled by Customer y Driver Not Found, el método de pago predominante es No_Payment_Info, lo cual es coherente con la naturaleza del proceso.
Por otro lado, los métodos Credit Card y Debit Card tienen una presencia mucho menor y se concentran casi exclusivamente en viajes exitosos, con conteos significativamente más bajos que Cash y UPI, lo que indica que, aunque están disponibles, no son los métodos preferidos por la mayoría de los usuarios.

3.3 TRAMIENTO DE DATOS

Debido a que se realizaron tres técnicas diferentes de minería de datos para este proyecto (clasificación, agrupamiento y reglas de asociación), para cada técnica se realizó un tratamiento de datos distinto, ya que cada una requiere una limpieza de datos diferentes respecto a los tipos de variables y la calidad de los datos.

Se identificaron algunas variables que presentaron dificultades debido a problemas de calidad, tipo de dato o compatibilidad con los algoritmos. El proceso de limpieza fue realizado en el flujo de trabajo de la herramienta KNIME mediante nodos de Python, nodos de filtrado y de normalización. A continuación, se presenta el tratamiento realizado a cada variable del conjunto de datos.

1. Variables categóricas generales: Booking_Status, Vehicle_Type, Pickup_Location, Drop_Location, Payment_Method
Estas variables categóricas presentaron problemas para el algoritmo de agrupación debido a que no puede ser utilizada directamente en el algoritmo de K-means porque este requiere de variables numéricas. No obstante, para la clasificación y las reglas de asociación sí fueron relevantes.

Tratamiento aplicado:

1- Se excluyeron del algoritmo de agrupamiento y se conservaron como referencia para la identificación de los registros. Para clasificación y reglas de asociación, se normalizaron y los valores faltantes se reemplazaron mediante categorías semánticas explícitas.

2- Se hizo un muestreo aleatorio del 30% total de los registros.

2. Variables categóricas sobre cancelaciones: Canceled_Rides_by_Customer, Canceled_Rides_by_Driver

Estas variables categóricas también presentaron problemas para el algoritmo de agrupación, además de tener valores faltantes cuando el viaje no fue cancelado, es decir, que fue completado exitosamente.

Tratamiento aplicado:

1- Se excluyeron del agrupamiento. Para clasificación y reglas de asociación, se reemplazaron los valores faltantes por categorías semánticas de No_Customer_Cancellation y No_Driver_Cancellation.

2- Se realizó un muestreo aleatorio del 30% total de los registros.

3. Variables categóricas de viajes incompletos: Incomplete_Rides, Incomplete_Rides_Reason

Se excluyeron del algoritmo de agrupación K-means. Presentaron valores faltantes cuando los viajes sí fueron completados.

Tratamiento aplicado:

1- Para clasificación y reglas de asociación, en la variable Incomplete_Rides se normalizó a valores binarios Yes y No. Además, en Incomplete_Rides_Reason, para los valores faltantes se reemplazaron por Not_Incomplete.

2- Se hizo un muestreo aleatorio del 30% total de los registros.

4. Variables numéricas de costo y distancia: Booking_Value, Ride_Distance

Se presentaron una amplia variabilidad de valores.

Tratamiento aplicado:

1- Se utilizaron para el algoritmo de agrupamiento, no para clasificación ni reglas de asociación. Normalización para evitar sesgos.

2- Se hizo un muestreo aleatorio del 30% total de los registros.

5. Variables numéricas de calificación: Driver_Ratings, Customer_Rating

Tratamiento aplicado:

1- Solo se utilizaron para el agrupamiento.

2- Se hizo un muestreo aleatorio del 30% total de los registros.

Las variables representaron los principales desafíos durante el tratamiento de datos, debido a problemas como valores faltantes, alta variabilidad y diferencias en el tipo de dato.

3.4 TAREA DE MINERÍA A APLICAR

Debido a la diversidad de la información contenida en nuestros conjuntos de datos, se implementarán tres diferentes tareas de minería de datos. Esto se decidió posterior al análisis de la información obtenida para entender el comportamiento de los viajes dentro de la presenta plataforma de viajes de Uber.

Agrupación

Aplicando K-Means, se logrará una organización de los viajes, esto en diferentes grupos que compartieran características similares. Como equipo, fue seleccionado porque es eficiente, fácil de interpretar y ampliamente utilizado en problemas de segmentación. Gracias a ello se podrán identificar distintos tipos de viajes, considerando las variables como la distancia recorrida, el valor del servicio y los tiempos de espera, lo que nos ayudará a la comprensión de los diferentes perfiles de viajes existentes.

Clasificación

Considerando el objetivo del proyecto de analizar el comportamiento del estado final de los viajes y evaluar la influencia de distancia de variables operativas, incorporándose como tarea, un modelo de clasificación supervisada.

Se eligió el modelo de decisión basado en el algoritmo CART, por su capacidad para manejar las variables categóricas generando un modelo bastante interpretable. Esto resulta adecuado para el presente proyecto ya que ayudará a la comprensión de como algunas variables y los indicadores de cancelación influyen en el estado del viaje. Por el algoritmo CART, se utilizó el índice de Gini y la poda para mejorar el sobreajuste y porque mejoran la generalización del modelo.

La elección de este modelo fue elegida ya que tiene gran capacidad para identificar patrones predictores que son claros y comprensibles porque aportan una perspectiva de análisis que completa los resultados de todo el proyecto.

Reglas de asociación

De acuerdo con el objetivo planteado, esta tarea resulta adecuada ya que el interés es descubrir las relaciones más frecuentes y significativas entre múltiples variables categóricas.

Las reglas de asociación que se generarán permitirán analizar de manera paralela las diferentes variables categóricas para así detectar combinaciones de los valores que aparecen en conjunto con gran frecuencia. Este modelo no necesita de una variable objetivo, lo que lo hace una herramienta ideal para en análisis exploratorio y descriptivo del comportamiento del presente conjunto de datos.

El uso de métricas como soporte, confianza y lift permiten evaluar la relevancia de las relaciones encontradas desde diferentes perspectivas. Así, las reglas de asociación producen un criterio cuantitativo que ayuda a identificar las relaciones del conjunto de datos que resultan más importantes y significativas para el mismo conjunto.
Por lo anterior, la elección de reglas de asociación fue por su capacidad para descubrir relaciones frecuentes y no evidentes entre variables, aportando conocimiento útil y comprensible que responde directamente al objetivo planteado del análisis.

La aplicación de las tareas de **agrupamiento**, **clasificación y reglas de asociación** permitirán analizar el conjunto de datos desde distintos puntos de vista. Cada tarea tiene como objetivo aportar información diferente, relevante y significativa: el modelo de agrupamiento ayudando a identificar tipos de viajes, la clasificación facilitando la predicción del estado de los viajes y las reglas de asociación permitiendo conocer relaciones frecuentes entre las variables. Gracias a esto se logrará una comprensión más completa del comportamiento de los viajes.

3.5 REPRESENTACIÓN DEL MODELO

3.5.1 Agrupamiento

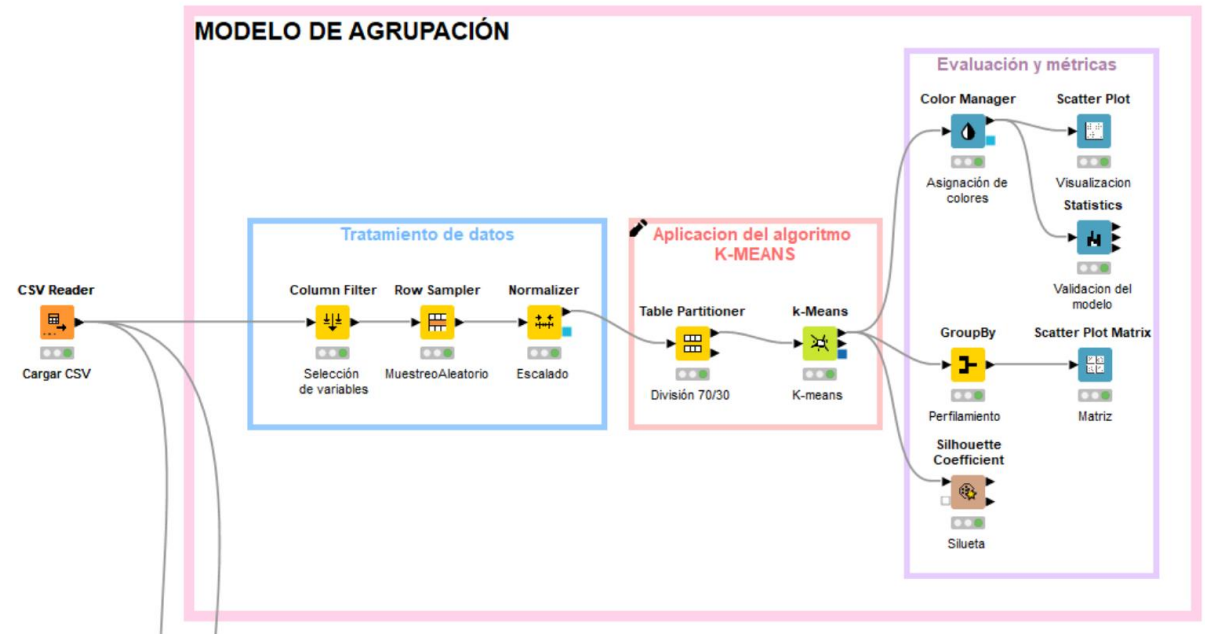


Figura 29. Modelo de agrupación K-means

3.5.2 Clasificación

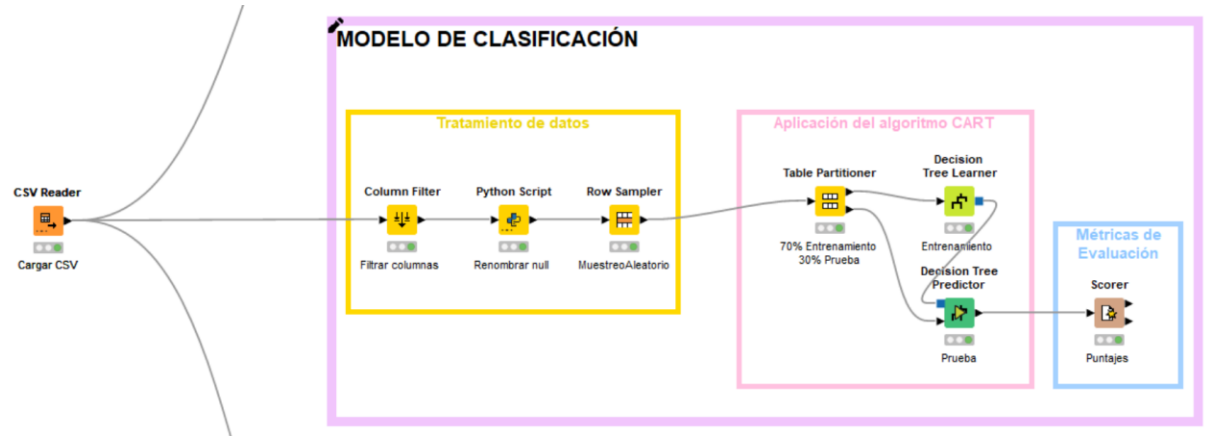


Figura 30. Modelo de clasificación CART

3.5.3 Reglas de Asociación

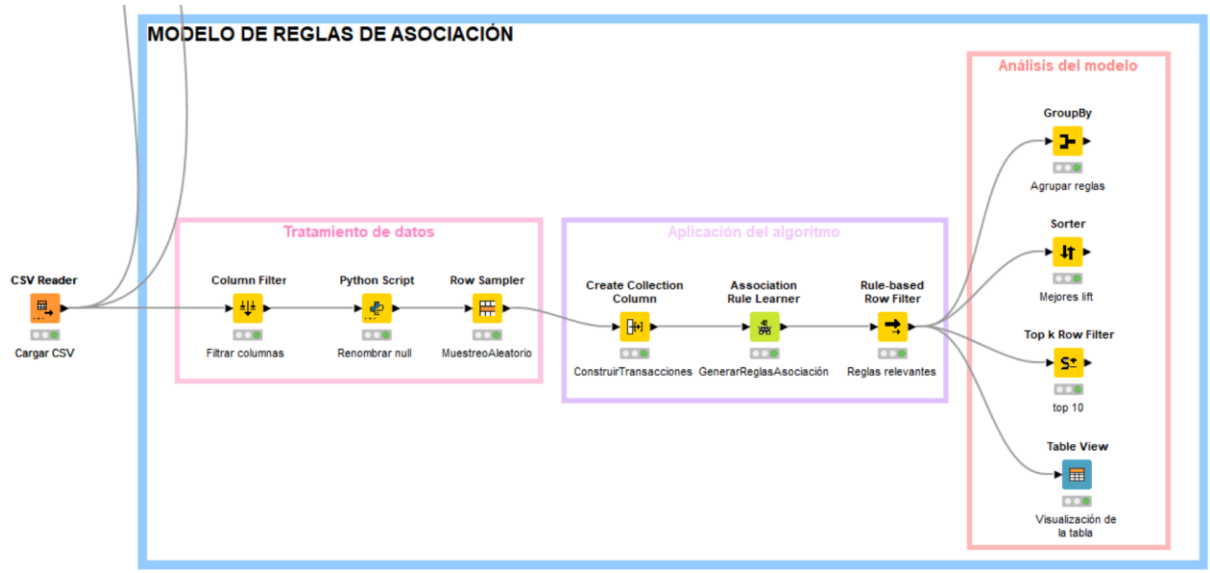


Figura 31. Modelo reglas de asociación

UNIDAD IV. RESULTADOS

4.1 AGRUPAMIENTO

En este caso se aplicó el algoritmo de K-Means, para así lograr la segmentación en grupos homogéneos, maximizando la similitud entre elementos del mismo grupo y minimizando la similitud entre grupos diferentes, con base a la distancia euclidiana entre las variables seleccionadas.

Todo esto se logró con un procesamiento previo de los datos, eliminando variables categóricas no relevantes, tratando valores faltantes y aplicando normalización Min-Max, con el fin de evitar variables con diferentes escalas, para que estas no influyeran de manera negativa.

El número de clústeres (K) fue definido con base en el método del codo (Elbow Method), analizando la variación de la suma de distancias intra–clúster. A partir del análisis, se seleccionó un valor de K = [indicar valor], ya que a partir de este punto la reducción del error deja de ser significativa.

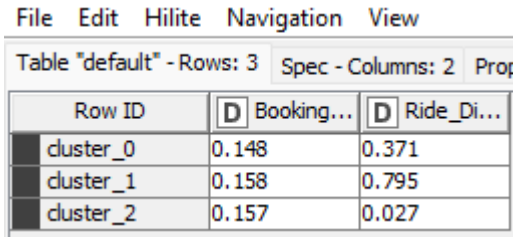

File Edit Hilite Navigation View

Table "default" - Rows: 3 Spec - Columns: 2 Prop

Row ID	D Booking...	D Ride_Di...
cluster_0	0.148	0.371
cluster_1	0.158	0.795
cluster_2	0.157	0.027

Figura 32. Clústeres

Así, el algoritmo logró separar los grupos claramente diferenciados, con un comportamiento similar.

Evaluación de métricas

El **coeficiente de silueta** mide qué tan similar es cada observación a su propio clúster en comparación con otros clústeres.

Los valores cercanos a **1** indican una buena separación entre grupos, valores cercanos a **0** indican solapamiento entre clústeres, y valores negativos sugieren una mala asignación.

Nuestro valor indica una segmentación aceptable, confirmando grupos coherentes y que están razonablemente separados.

Interpretación del clúster

-Clúster 1: Viajes cortos, bajo costo y alta frecuencia

-Clúster 2: viajes de distancia media con costos moderados

-Clúster 3: viajes largos y de mayor valor económico

El modelo fue capaz de identificar patrones relevantes dentro del conjunto de datos, generando grupos con características bien definidas, por lo que resulto adecuado para

explorar estructuras internas en los datos y apoyar procesos de análisis exploratorio y segmentación.

4.2 CLASIFICACIÓN

Para el modelo de clasificación, se entrenó un modelo de árbol de decisión basado en el algoritmo CART, utilizando el índice de Gini como criterio de división. El conjunto de datos fue dividido en un 70% para entrenamiento y 30% para prueba, aplicando técnicas de poda con el fin de reducir el sobreajuste y mejorar la capacidad de generalización del modelo.

La evaluación del modelo se realizó sobre el conjunto de prueba mediante la matriz de confusión y la métrica de exactitud.

La exactitud (accuracy) mide la proporción de instancias correctamente clasificadas respecto al total de observaciones evaluadas. Esta métrica proporciona una visión general del rendimiento del modelo (Google, 2025).

La matriz de confusión permite analizar de forma detallada las predicciones del modelo ya que muestra la cantidad de instancias correctamente clasificadas y los errores de clasificación entre distintas clases (IBM, 2025).

El coeficiente kappa de Cohen mide el grado de concordancia entre las predicciones del modelo y los valores reales. Valores cercanos a 1 indican que la concordancia es casi perfecta, los valores cercanos a 0 indican una concordancia débil (Ortega, 2025).

Desempeño del modelo

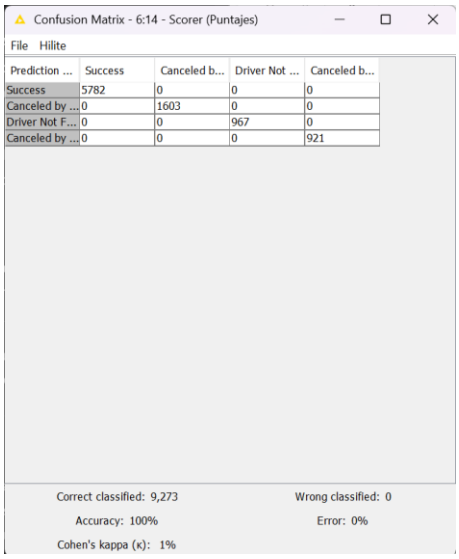


Figura 33. Resultados modelo de clasificación

Explicación de las métricas

Los resultados muestran una exactitud del 100%, lo que indica que el total de instancias del conjunto de prueba fueron clasificadas correctamente. Por lo tanto, el porcentaje del error fue de 0%, indicando lo mismo mencionado.

La matriz de confusión muestra la confirmación de esos resultados ya que no se observan valores fuera de la diagonal principal. Se clasificaron de manera correcta 5,782 instancias que corresponden a la clase Success, 1,603 instancias correspondientes a Canceled by Customer, 967 instancias de Driver Not Found y 921 instancias de Canceled by Driver.

El coeficiente kappa de Cohen fue cercano a 0.01 lo que indica concordancia limitada cuando se ajusta por la probabilidad de acuerdo con el azar.

El valor de la exactitud es la evidencia de que el modelo fue capaz de aprender las reglas claras que permiten separar de forma correcta as distintas clases del estado final de los viajes realizados. Como se mencionó anteriormente, este desempeño es reflejado en la matriz de confusión, ya que existe una ausencia de errores de clasificación lo que indica que las variables utilizadas tienen información altamente discriminante.

El valor reducido en el coeficiente kappa de Cohen se puede explicar por la naturaleza de las variables que fueron incluidas en el modelo. En el presente conjunto de datos algunos de los atributos predictivos están altamente relacionados con la variable objetivo, por lo que esta relación determinada provoca que la concordancia observada no dependa del azar, sino de las reglas explícitamente aprendidas por el modelo, esto reduce la utilidad de kappa como métrica.

En términos generales, el presente modelo de clasificación mostró un desempeño sobresaliente como se pudo notar, ya que logró clasificar correctamente todas las instancias del conjunto de prueba. Tuvo una elevada precisión por lo que ofrece una estructura interpretable que permite identificar claramente las variables que más influyen en la determinación del estado final del viaje.

El modelo cumple de manera satisfactoria con el objetivo planteado y complementa los resultados obtenidos de los 2 modelos restantes. El desempeño del modelo nos hace entender que es particularmente adecuado para análisis explicativo y la comprensión de patrones en los presentes datos.

4.3 REGLAS DE ASOCIACIÓN

Con el objetivo de identificar patrones frecuentes y las relaciones relevantes entre las variables categóricas del dataset, se aplicó el modelo de reglas de asociación (Apriori).

El análisis se centró en encontrar las combinaciones de características que incrementan de manera significativa la probabilidad de determinados resultados, en particular, los distintos tipos de cancelación, la ausencia de información de pago y el estado final de la reserva.

Estas reglas fueron evaluadas usando las métricas de soporte, confianza y lift. Se priorizaron aquellas con mayor lift por su alta capacidad para identificar relaciones relevantes entre las variables.

Desempeño del modelo

Row ID	Support	Confidence	Lift	Consequent	implies	Items
rule79	0.026	1	9.701	Canceled by Customer	<---	[Driver asked to cancel,No_Driver_Cancellation]
rule85	0.026	1	9.701	Canceled by Customer	<---	[No,Driver asked to cancel]
rule89	0.026	1	9.701	Canceled by Customer	<---	[Not_Incomplete,Driver asked to cancel]
rule91	0.026	1	9.701	Canceled by Customer	<---	[No_Payment_Info,Driver asked to cancel]
rule390	0.032	1	9.701	Canceled by Customer	<---	[Driver is not moving towards pickup location,No_Driver_Cancellation]

Figura 34. Resultado de reglas de asociación

La figura 31 muestra la salida directa del nodo Association Rule Learner de KNIME filtrada con las 5 mejores reglas del modelo. Se puede observar las reglas generadas junto con sus métricas principales como lo son el soporte, la confianza y lift.

Reglas de Asociación más relevantes

Tabla 2. Reglas de Asociación

Antecedente	Consecuente	Support	Confidence	Lift
Conductor no se dirige al punto de recogida	Cancelado por el cliente	0.032	1.00	9.70
Conductor solicita la cancelación	Cancelado por el cliente	0.026	1.00	9.70
Sin información de pago y solicitud de cancelación del conductor	Cancelado por el cliente	0.026	1.00	9.70

Nota. Elaboración propia

Explicación de las métricas

El soporte indica la proporción de registros en los que se cumple simultáneamente el antecedente y el consecuente, lo que refleja la frecuencia de la regla dentro del conjunto de datos (IBM, 2014).

La confianza representa la probabilidad de que ocurra el consecuente dado que se cumpla el antecedente. (IBM, 2014).

El lift, mide la fuerza de la asociación en comparación con la ocurrencia esperada por azar; los valores mayores a 1 en esta métrica, indican una dependencia positiva entre las variables (IBM, 2014).

Los valores del soporte se encuentran entre 0.026 y 0.032, lo que indica que las reglas seleccionadas en la tabla anterior ocurren en aproximadamente el 2.6% y el 3.2% de los viajes analizados. Si bien, los valores de soporte pueden parecer bajos, no lo son en el contexto del presente análisis dado el gran tamaño del conjunto de datos y la naturaleza específica de los eventos analizados, estos valores representan miles de observaciones reales.

En todas las reglas seleccionadas, la confianza alcanza el valor máximo de 1, lo que implica el 100% de los casos observados en los datos, el consecuente ocurre siempre que se representa el antecedente. Esto evidencia una relación bien determinada en el conjunto de datos lo que refuerza la consistencia de las asociaciones encontradas.

Por otro lado, el lift es la métrica más relevante para la interpretación de las reglas, los valores de lift son cercanos a 9.7, lo que quiere decir que la probabilidad de cancelación por parte del cliente es casi diez veces mayor cuando se cumplen las condiciones del antecedente. Estos valores reflejan asociaciones fuertes y poco o no triviales.

Interpretación de las reglas seleccionadas

La primera regla, indica que cuando el conductor no se dirige hacia el punto de recogida del cliente, el viaje es cancelado por el cliente en todos los casos observados. El soporte de esta regla muestra que este comportamiento ocurre en una proporción significativa de los viajes analizados, mientras que la confianza igual a 1, confirma que este resultado es consistente. De igual manera, el valor del lift indica que este patrón constituye un factor crítico que incrementa de manera significativa la probabilidad de cancelación, lo que sugiere deficiencias operativas en la asignación o seguimiento de los conductores.

La segunda regla establece que cuando el conductor solicita explícitamente la cancelación del viaje, el cliente termina cancelando el servicio en el 100% de los casos. El valor de confianza indica que la elección del cliente final esta mayormente influenciada por la acción que tenga conductor. Asimismo, el lift indica que esta relación es más fuerte que la situación promedio de cancelaciones, lo que destaca la importancia del comportamiento del conductor en la experiencia del usuario.

La tercera regla está relacionada con la ausencia de información de pago. En este caso, la combinación de falta de información de pago y la solicitud de cancelación por parte del conductor hace frecuente la cancelación del viaje por parte del cliente. El valor de soporte confirma que esta situación es presentada con frecuencia, mientras que la confianza y el lift indican que la interacción de factores operativos y de información incrementa visiblemente la probabilidad de cancelación. El resultado puede indicar posibles fallos en los procesos previos a la confirmación del viaje y a la comunicación entre el sistema, el conductor y el cliente.

Los resultados obtenidos del modelo de reglas de asociación muestran que el comportamiento del conductor y algunas causas de circunstancias operativas, son influyentes en la decisión de cancelación por parte del cliente. Esto proporciona información importante para la toma de decisiones y para comprender el área de mejora tanto en la parte operativa como en la relación con la experiencia del usuario.

UNIDAD V. CONCLUSIONES

El análisis realizado en este trabajo sobre el conjunto de datos de viajes registrados en plataformas de transporte bajo demanda como Uber y Ola Cabs en el mes de julio de 2024, el cual contenía más de 100,000 registros, permitió comprender el comportamiento de este tipo de servicios, identificar patrones sobre los viajes y qué factores influyen en ser completados con éxito, o en su defecto, la cancelación de estos.

Los resultados obtenidos muestran que la mayoría de los viajes se completan con éxito, lo que demuestra la eficiencia del sistema de reserva. Sin embargo, se observó que los principales factores asociados a las cancelaciones de los viajes tienen que ver con la disponibilidad de los conductores, los tiempos de respuesta y la comunicación entre el cliente y el conductor, por lo que se concluye que las cancelaciones dependen de diferentes factores que interactúan mutuamente durante el proceso del servicio de transporte bajo demanda.

Se identificó una gran diversidad en los tipos de viaje que se realizan en estas plataformas, debido a que existen trayectos cortos que son de bajo costo, los cuales pueden representar desplazamientos cotidianos de los usuarios. Asimismo, se identificaron trayectos más largos y de mayor costo. Lo anterior demuestra que este servicio es utilizado por distintos perfiles de clientes con necesidades variadas. Esto implica que las estrategias operativas y de mejora deben tener en cuenta esta diversidad y no asumir que solo un tipo de perfil de clientes utiliza sus servicios.

Para los tiempos de espera, tanto el conductor como el cliente tienen la responsabilidad para que la experiencia del servicio sea buena. Aunque los tiempos de la mayoría de los viajes son razonables, su variabilidad puede afectar a la probabilidad de la cancelación del viaje. Además, las calificaciones que los clientes y los conductores se otorgan mutuamente son coherentes, lo que indica un alto grado de satisfacción.

Es importante fortalecer los procesos de asignación de conductor, además del seguimiento y comunicación dentro de la plataforma para asegurar una menor probabilidad de que estas incidencias sucedan debido a que la cancelación de viajes está relacionada con la conducta del conductor junto con algunos componentes operativos del sistema de reservas, es decir, si el chofer no se desplaza al lugar de inicio o si aparecen problemas antes de que inicie el viaje, es posible que se anule el servicio.

Los resultados obtenidos coinciden con los estudios revisados los cuales indican que las cancelaciones de los viajes están fuertemente relacionadas con los tiempos de espera altos, problemas con la asignación de conductores y fallas en la comunicación. Además, la

diversidad de necesidades de los clientes, lo que refleja los viajes de menor y mayor duración y costo.

El presente trabajo muestra que el empleo de algoritmos y técnicas de minería de datos posibilita convertir enormes volúmenes de información en conocimiento aplicable para la toma de decisiones con el fin de optimizar la eficiencia, perfeccionar la experiencia del usuario y formular estrategias para disminuir las cancelaciones mediante la detección de patrones y conductas significativas que son imposibles de detectar a simple vista por los humanos.

REFERENCIAS

Agrawal, R., Imieliński, T., & Swami, A. (1993). Mining association rules between sets of items in large databases. Proceedings of the ACM SIGMOD International Conference on Management of Data, 207–216.

Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). Classification and regression trees. Wadsworth International Group.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc.

Díaz, J. (2024). Aplicación de la minería de datos espacial basado en técnicas de agrupamiento para detectar los niveles de congestionamiento del tráfico vehicular en la ciudad de Trujillo. SCIÉNDO INGENIUM, 20(2), 11-37. https://doi.org/10.17268/rev.cyt.2024.02.01

Google. (2025). Classification: Accuracy, precision & recall (Machine Learning Crash Course). Google Developers. https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=es-419

Han, J., Kamber, M., & Pei, J. (2012). Data mining: Concepts and techniques (3rd ed.). Morgan Kaufmann.

IBM. (2014). Characteristics of association rules and item sets. IBM Db2 11.1.0 documentation. https://www.ibm.com/docs/es/db2/11.1.0?topic=visualizer-characteristics-association-rules-item-sets

IBM. (2025). ¿Qué es una matriz de confusión? IBM Think. https://www.ibm.com/mx-es/think/topics/confusion-matrix

Lumbreras, M. (2020). Evaluación de análisis de clustering jerárquico en datos moleculares de alta dimensión [Trabajo Final de Máster, Universidad Oberta de Catalunya]. Repositorio UOC. http://openaccess.uoc.edu/webapps/o2/handle/10609/120648

Mamani, Z., Del Pino, L., & Cortez, A. (2017). Minería de datos distribuida usando clustering k-means en la predictibilidad del proceso petitorio en una organización pública. Industrial Data, 20(2), 123-129. https://doi.org/10.15381/idata.v20i2.13949

Ortega. (2025). Kappa de Cohen: qué es y cómo se interpreta. QuestionPro. https://www.questionpro.com/blog/es/kappa-de-cohen/

Sahu, H., Sharma, S., & Gondhalakar, S. (2011). A brief overview on data mining survey. International Journal of Computer Technology and Electronics Engineering, 1(3), 114-121.

Scholl, L., Sabogal-Cardona, O., Oviedo, D., & Bedoya-Maya, F. (2021, 15 de noviembre). Movilidad por aplicación: una agenda de investigación para fomentar movilidad inclusiva y sostenible. Moviliblog - Banco Interamericano de Desarrollo. https://www.iadb.org/es/blog/transporte/movilidad-por-aplicacion-una-agenda-de-investigacion-para-fomentar-movilidad-inclusiva-y-sostenible

Shamie, M., & Almustafa, M. M. (2021). Improving association rule mining using clustering-based data mining model for traffic accidents. Research in Computer and Emerging Sciences. https://www.iieta.org/journals/rces/paper/10.18280/rces.080301

Sun, H., Lv, Z., Li, J., Xu, Z., & Sheng, Z. (2023). Will the Order Be Canceled? Order Cancellation Probability Prediction Based on Deep Residual Model. Transportation Research Record, 2677(7), 570-583. https://doi.org/10.1177/03611981221144279

Ulloa, N., Holgado, L., Vílchez, Y., & Quispe, D. (2022). Técnicas supervisadas de minería de datos para el análisis del rendimiento académico de los estudiantes de la Universidad Nacional Amazónica de Madre de Dios. Revista Amazónica de Ciencias Básicas y Aplicadas, 1(2), e190. https://doi.org/10.55873/racba.v1i2.190

Vassallo, J., Gómez, J., & Aguilera, Á. (2018). Ride-hailing en España: ¿Qué opinan los usuarios de Uber y Cabify frente al taxi? Revista de Obras Públicas, (3604), 24-29. https://dialnet.unirioja.es/servlet/articulo?codigo=6765294

Wang, H., & Yang, H. (2019). Ridesourcing systems: A framework and review. Transportation Research Part B: Methodological, 129, 122-155. https://doi.org/10.1016/j.trb.2019.07.009